PROJET DE FIN D'ÉTUDES

Filière : Génie Informatique / Intelligence Artificielle

CMAD-Net

Cross-Modal Attention Detection Network

pour la Détection d'Anomalies 3D

Réalisé par : Souhaib Chettou

Année universitaire : 2025 – 2026

Remerciements

Je tiens à exprimer ma profonde gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet de fin d'études.

Je remercie tout d'abord mon encadrant académique pour ses précieux conseils, son suivi régulier et ses orientations scientifiques qui ont guidé ce travail de recherche.

Je remercie également mon encadrant professionnel pour m'avoir accueilli au sein de son équipe, pour sa confiance et pour les moyens techniques mis à ma disposition.

Mes remerciements vont aussi à l'ensemble des membres du jury pour l'honneur qu'ils me font en évaluant ce travail.

Enfin, je remercie ma famille et mes amis pour leur soutien indéfectible tout au long de mon parcours académique.

Résumé

Ce projet de fin d'études porte sur la conception et le développement de **CMAD-Net** (Cross-Modal Attention Detection Network), un réseau de neurones profond pour la détection d'anomalies 3D multi-modale non-supervisée. Le système exploite conjointement les images RGB et les données de profondeur (Depth) via un mécanisme d'attention croisée innovant (CMCA), couplé à un paradigme de Reverse Distillation Teacher-Student. L'architecture intègre un backbone Vision Transformer (ViT-B/16) pré-entraîné avec DINO, un Feature Pyramid Network multi-échelles, et une fusion adaptative par catégorie d'objets. Évalué sur le benchmark MVTec 3D-AD (10 catégories), le modèle atteint un P-AUROC moyen de 0.952 et un AUPRO@30% de 0.816, démontrant son efficacité pour la localisation précise des anomalies industrielles.

Mots-clés : Détection d'anomalies, Vision par ordinateur, Deep Learning, Vision Transformer, Attention croisée, Multi-modal, 3D, Reverse Distillation.

Abstract

This final year project focuses on the design and development of **CMAD-Net** (Cross-Modal Attention Detection Network), a deep neural network for unsupervised multi-modal 3D anomaly detection. The system jointly exploits RGB images and depth data through an innovative cross-modal cross-attention mechanism (CMCA), coupled with a Teacher-Student Reverse Distillation paradigm. The architecture integrates a Vision Transformer backbone (ViT-B/16) pre-trained with DINO, a multi-scale Feature Pyramid Network, and adaptive category-specific score fusion. Evaluated on the MVTec 3D-AD benchmark (10 categories), the model achieves a mean P-AUROC of 0.952 and

AUPRO@30% of 0.816, demonstrating its effectiveness for precise industrial anomaly localization.

Keywords : Anomaly detection, Computer Vision, Deep Learning, Vision Transformer, Cross-attention, Multi-modal, 3D, Reverse Distillation.

Liste des Abréviations

Abréviation	**Signification**
AUROC	Area Under the Receiver Operating Characteristic
AUPRO	Area Under the Per-Region Overlap
BN	Batch Normalization
CMAD-Net	Cross-Modal Attention Detection Network
CMCA	Cross-Modal Cross-Attention
CNN	Convolutional Neural Network
DINO	Self-Distillation with NO Labels
FPN	Feature Pyramid Network
FPR	False Positive Rate
GELU	Gaussian Error Linear Unit
GPU	Graphics Processing Unit
GT	Ground Truth
MHA	Multi-Head Attention
MSE	Mean Squared Error
MVTec 3D-AD	MVTec 3D Anomaly Detection
PFE	Projet de Fin d'Études
PRO	Per-Region Overlap
ReLU	Rectified Linear Unit
RGB	Red Green Blue
ViT	Vision Transformer

Table des matières

Remerciements i

Résumé ii

Liste des Abréviations iv

Liste des figures viii

Liste des tableaux ix

Introduction Générale 1

1 Contexte Général du Projet 3

Introduction du chapitre . . . 3

1.1 Organisme d'accueil . . . 3

1.2 Contexte du projet . . . 3

1.2.1 Périmètre et description du projet . . . 3

1.2.2 Nature du projet . . . 4

1.2.3 L'existant . . . 4

1.2.4 Problématique . . . 4

1.2.5 Objectifs et solution proposée . . . 5

1.2.6 Mission dans le projet . . . 6

1.2.7 Livrables . . . 6

1.2.8 Méthodologie de développement . . . 7

1.2.9 Planification prévisionnelle . . . 7

Conclusion du chapitre . . . 8

2 État de l'Art 9

Introduction du chapitre . . . 9

2.1 Concepts clés . . . 9

2.1.1 Détection d'anomalies industrielles . . . 9

2.1.2 Vision Transformer (ViT) . . . 9

2.1.3 Attention croisée (Cross-Attention) . . . 10

2.1.4 Reverse Distillation 10
2.1.5 Feature Pyramid Network (FPN) 10
2.1.6 Benchmark MVTec 3D-AD 10
2.2 Analyse critique des solutions existantes 10
2.2.1 Approches par reconstruction 10
2.2.2 Approches par Memory Bank 10
2.2.3 Approches Teacher-Student 11
2.2.4 Approches Reverse Distillation 11
2.2.5 Approches multi-modales 3D 11
2.2.6 Tableau comparatif 11
2.3 Synthèse et positionnement 12
Conclusion du chapitre 12

3 Analyse et Conception **13**
Introduction du chapitre 13
3.1 Analyse des besoins 13
3.1.1 Besoins fonctionnels 13
3.1.2 Besoins non-fonctionnels 13
3.2 Conception architecturale 14
3.2.1 Architecture globale de CMAD-Net 14
3.2.2 Diagramme de classes UML 14
3.2.3 Spécifications des modules 15
3.3 Conception détaillée des modules 16
3.3.1 ViT-B/16 DINOv2 Encoder 16
3.3.2 Feature Pyramid Network (FPN) 16
3.3.3 Cross-Modal Cross-Attention (CMCA) 16
3.3.4 Student Decoder (Reverse Distillation) 16
3.3.5 Adaptive Score Fusion 17
3.3.6 Fonctions de loss 17
3.4 Architecture technique 17
Conclusion du chapitre 18

4 Réalisation **19**
Introduction du chapitre 19
4.1 Technologies utilisées 19
4.2 Réalisation 20
4.2.1 Configuration des hyperparamètres 20
4.2.2 Sortie d'entraînement — Phase 1 (Reverse Distillation) 20
4.2.3 Sortie de calibration — Phase 2 20
4.2.4 Sortie d'évaluation 21

4.2.5 Structure du code source 21
4.3 Résultats expérimentaux 21
4.3.1 Résultats par catégorie 21
4.3.2 Moyennes globales 22
4.3.3 Paramètres de calibration 23
4.3.4 Analyse de la convergence 23
4.3.5 Analyse par type de catégorie 23
Conclusion du chapitre 24

Conclusion Générale **25**

Références **27**

A Hyperparamètres détaillés **28**

B Glossaire **29**

Table des figures

1.1 Diagramme de Gantt prévisionnel du projet CMAD-Net 8

3.1 Architecture globale de CMAD-Net 14
3.2 Diagramme de classes UML de CMAD-Net 15

Liste des tableaux

1.1 Objectifs du projet CMAD-Net 5
1.2 Solutions proposées par CMAD-Net 6
1.3 Livrables du projet 7
1.4 Planification des sprints Scrum 7

2.1 Comparaison des approches de détection d'anomalies 11
2.2 Comparaison des backbones pour la détection d'anomalies 12

3.1 Besoins fonctionnels du système 13
3.2 Spécifications des modules de CMAD-Net 15
3.3 Dimensions tensorielles par module 17

4.1 Technologies et bibliothèques utilisées 19
4.2 Configuration des hyperparamètres 20
4.3 Résultats expérimentaux par catégorie 22
4.4 Moyennes globales des métriques 22
4.5 Paramètres de calibration par catégorie 23

A.1 Configuration complète des hyperparamètres 28

Introduction Générale

Le contrôle qualité industriel constitue un enjeu stratégique majeur pour les entreprises manufacturières. Dans un contexte de production de masse, la détection automatique des défauts sur les produits est devenue indispensable pour maintenir des standards de qualité élevés tout en optimisant les coûts de production. Les anomalies — fissures, contaminations, déformations, trous — peuvent compromettre la fonctionnalité, la sécurité ou l'esthétique des produits, entraînant des pertes financières considérables.

Traditionnellement, l'inspection visuelle est réalisée par des opérateurs humains, une approche coûteuse, subjective et sujette à la fatigue. L'avènement du deep learning et de la vision par ordinateur a ouvert de nouvelles perspectives pour l'automatisation de cette tâche. Cependant, la détection d'anomalies industrielles pose un défi particulier : les anomalies sont, par nature, rares et imprévisibles. C'est pourquoi les approches **non-supervisées** — qui n'utilisent que des échantillons normaux pendant l'entraînement — se sont imposées comme le paradigme dominant.

Un autre défi réside dans la **multi-modalité**. Les caméras RGB capturent les anomalies visuelles (couleur, texture), mais sont aveugles aux défauts géométriques (bosses, creux). Les capteurs de profondeur capturent la géométrie 3D, mais avec une résolution inférieure. La **fusion intelligente** de ces deux modalités est essentielle pour une détection complète et robuste.

Dans ce contexte, le présent projet de fin d'études propose **CMAD-Net** (Cross-Modal Attention Detection Network), une architecture de réseau de neurones profond qui aborde ces défis à travers trois innovations principales :

1. **L'attention croisée inter-modale (CMCA)** : un mécanisme de fusion profonde qui permet aux features RGB et Depth de s'enrichir mutuellement via un Transformer cross-attention.
2. **La Reverse Distillation Teacher-Student** : un paradigme de détection où un student decoder apprend à reconstruire les features d'un teacher sur les échantillons normaux, révélant les anomalies par discordance.
3. **Le backbone Vision Transformer (ViT-B/16 DINOv2)** : des représentations auto-supervisées riches extraites par un Vision Transformer pré-entraîné.

Le système est évalué sur le benchmark **MVTec 3D-AD**, la référence pour la détection d'anomalies 3D industrielles, couvrant 10 catégories d'objets avec des anomalies variées.

Ce rapport est organisé en quatre chapitres :

— Le **Chapitre 1** présente le contexte général du projet, la problématique, les objectifs, la méthodologie et la planification.

— Le **Chapitre 2** dresse un état de l'art des approches de détection d'anomalies, avec une analyse critique et le positionnement de CMAD-Net.

— Le **Chapitre 3** détaille l'analyse des besoins et la conception architecturale du système.

— Le **Chapitre 4** couvre la réalisation, les technologies utilisées et les résultats expérimentaux.

Chapitre 1

Contexte Général du Projet

Introduction du chapitre

Ce premier chapitre pose les fondations du projet CMAD-Net. Nous présentons l'organisme d'accueil, le contexte, le périmètre du projet, l'analyse de l'existant, la problématique identifiée et les objectifs fixés. Nous détaillons la méthodologie de développement adoptée et la planification prévisionnelle sous forme de diagramme de Gantt.

1.1 Organisme d'accueil

Le projet CMAD-Net a été réalisé dans le cadre d'un projet de fin d'études en Génie Informatique, spécialité Intelligence Artificielle. Le travail s'inscrit dans le domaine de la recherche appliquée en vision par ordinateur et deep learning, avec un focus sur la détection d'anomalies industrielles 3D.

L'environnement de travail dispose des ressources suivantes :

— **Infrastructure de calcul** : Machines locales et plateforme cloud Kaggle (GPU NVIDIA)
— **Données** : Dataset MVTec 3D-AD (benchmark académique de référence)
— **Outils** : Environnement Python avec PyTorch, bibliothèques de vision par ordinateur

1.2 Contexte du projet

1.2.1 Périmètre et description du projet

Le projet CMAD-Net consiste en la **conception, le développement et l'évaluation** d'un système de détection d'anomalies 3D basé sur le deep learning multi-modal. Le périmètre couvre :

— **L'ingénierie des données** : Pipeline de chargement et pré-traitement des images RGB et des données de profondeur 3D (conversion depth → normal maps)
— **L'architecture du modèle** : Conception d'un réseau intégrant un Vision Transformer, un FPN, un mécanisme d'attention croisée et un décodeur student
— **L'entraînement** : Pipeline en 2 phases (Reverse Distillation + Calibration)
— **L'évaluation** : Mesure des performances sur 10 catégories avec un ensemble complet de métriques

1.2.2 Nature du projet

Ce projet est un **sujet de recherche appliquée** combinant recherche bibliographique, innovation architecturale, développement logiciel et évaluation expérimentale. Il s'agit d'une **évolution** du modèle TRD (Teacher Reverse Distillation) existant, avec des améliorations significatives :

— Remplacement du backbone CNN (WideResNet-50) par un Vision Transformer (ViT-B/16 DINOv2)
— Introduction d'un mécanisme d'attention croisée (CMCA) remplaçant les Crossmodal Tuners CNN
— Adoption du paradigme Reverse Distillation en remplacement du Memory Bank
— Post-traitement non-paramétrique remplaçant le FP Filter paramétrique

1.2.3 L'existant

Avant CMAD-Net, plusieurs solutions existaient pour la détection d'anomalies 3D :

a) TRD (Teacher Reverse Distillation) — Backbone WideResNet-50, fusion par Crossmodal Tuners CNN, détection par Memory Bank, post-traitement par FP Filter paramétrique. *Limitation* : fusion tardive et superficielle ; le FP Filter peut supprimer les vraies anomalies.

b) PatchCore — Memory Bank de patches locaux avec recherche de plus proches voisins. *Limitation* : coût mémoire et temps d'inférence élevés ; principalement 2D.

c) RD4AD — Teacher-Student avec décodeur inversé. *Limitation* : unimodal (RGB uniquement).

d) AST — Student-Teacher avec architectures asymétriques. *Limitation* : pas de mécanisme cross-modal explicite.

1.2.4 Problématique

L'analyse de l'existant révèle la problématique suivante :

> ***Problématique principale :*** *Comment concevoir un système de détection d'anomalies 3D capable de fusionner* ***profondément*** *et* ***dynamiquement*** *les informations visuelles (RGB) et géométriques (Depth), tout en maintenant une détection précise au niveau pixel ?*

Les sous-problèmes identifiés sont :

1. **Fusion superficielle** : Les méthodes existantes combinent les modalités tardivement
2. **Représentations limitées** : Les backbones CNN capturent des features locales, manquant le contexte global
3. **Détection mono-échelle** : Beaucoup de méthodes n'exploitent que 3 niveaux de features
4. **Post-traitement risqué** : Les modules paramétriques peuvent supprimer les vraies anomalies
5. **Fusion rigide** : L'importance des modalités varie selon le type d'objet

1.2.5 Objectifs et solution proposée

Le Tableau 1.1 présente les objectifs du projet.

TABLE 1.1 – Objectifs du projet CMAD-Net

N°	Objectif	Priorité
O1	Concevoir une architecture multi-modale avec fusion profonde par attention croisée	Haute
O2	Implémenter le paradigme Reverse Distillation pour la détection d'anomalies	Haute
O3	Intégrer un backbone Vision Transformer (ViT-B/16 DINOv2)	Haute
O4	Développer un FPN multi-échelles à 4 niveaux	Moyenne
O5	Implémenter une fusion adaptative par catégorie	Moyenne
O6	Évaluer sur les 10 catégories de MVTec 3D-AD	Haute
O7	Atteindre des performances compétitives (P-AUROC > 0.95)	Haute

Le Tableau 1.2 résume comment CMAD-Net adresse chaque sous-problème.

TABLE 1.2 – Solutions proposées par CMAD-Net

Sous-problème	**Solution CMAD-Net**
Fusion superficielle	CMCA : Attention croisée symétrique à chaque niveau FPN
Représentations limitées	ViT-B/16 DINOv2 : Backbone Transformer avec attention globale
Détection mono-échelle	FPN à 4 niveaux avec pathway top-down
Post-traitement risqué	Post-traitement non-paramétrique (Gaussian smoothing)
Fusion rigide	Adaptive Fusion : Poids Softmax appris par catégorie

1.2.6 Mission dans le projet

La mission couvre l'intégralité du cycle de vie :

1. **Recherche bibliographique** : Étude de l'état de l'art
2. **Conception architecturale** : Design des 6 modules
3. **Développement** : Implémentation en Python/PyTorch
4. **Entraînement et optimisation** : Entraînement sur MVTec 3D-AD
5. **Évaluation et analyse** : Mesure des performances
6. **Rédaction** : Documentation et rapport de PFE

1.2.7 Livrables

Le Tableau 1.3 présente les livrables du projet.

TABLE 1.3 – Livrables du projet

N°	Livrable	Description	Format
L1	Code source CMAD-Net	Architecture complète (7 modules)	Python
L2	Script d'entraînement	Pipeline en 2 phases avec logging	Python
L3	Module d'évaluation	10 métriques standardisées	Python
L4	Dataset pipeline	Chargement et pré-traitement	Python
L5	Checkpoints	Poids pour 10 catégories	.pth
L6	Logs d'entraînement	Courbes de loss et métriques	Texte
L7	Documentation	Architecture et code	Markdown
L8	Rapport de PFE	Le présent document	PDF

1.2.8 Méthodologie de développement

Nous avons adopté la méthodologie **Scrum adaptée** (Agile), avec des sprints de 2 semaines. Ce choix se justifie par la nature exploratoire du projet et la nécessité d'adaptabilité.

Le Tableau 1.4 détaille la planification des sprints.

TABLE 1.4 – Planification des sprints Scrum

Sprint	Durée	Objectifs	Livrable
Sprint 0	Sem. 1–2	Recherche biblio, installation env.	État de l'art
Sprint 1	Sem. 3–4	ViT Encoder + FPN	Backbone
Sprint 2	Sem. 5–6	CMCA + Student Decoder	Pipeline T-S
Sprint 3	Sem. 7–8	Intégration + Fusion + Loss	Modèle complet
Sprint 4	Sem. 9–10	Dataset + entraînement	1er entraînement
Sprint 5	Sem. 11–12	Optimisation + évaluation	10 catégories
Sprint 6	Sem. 13–14	Analyse + rédaction	Rapport final

1.2.9 Planification prévisionnelle

La Figure 1.1 présente le diagramme de Gantt du projet, couvrant 14 semaines.

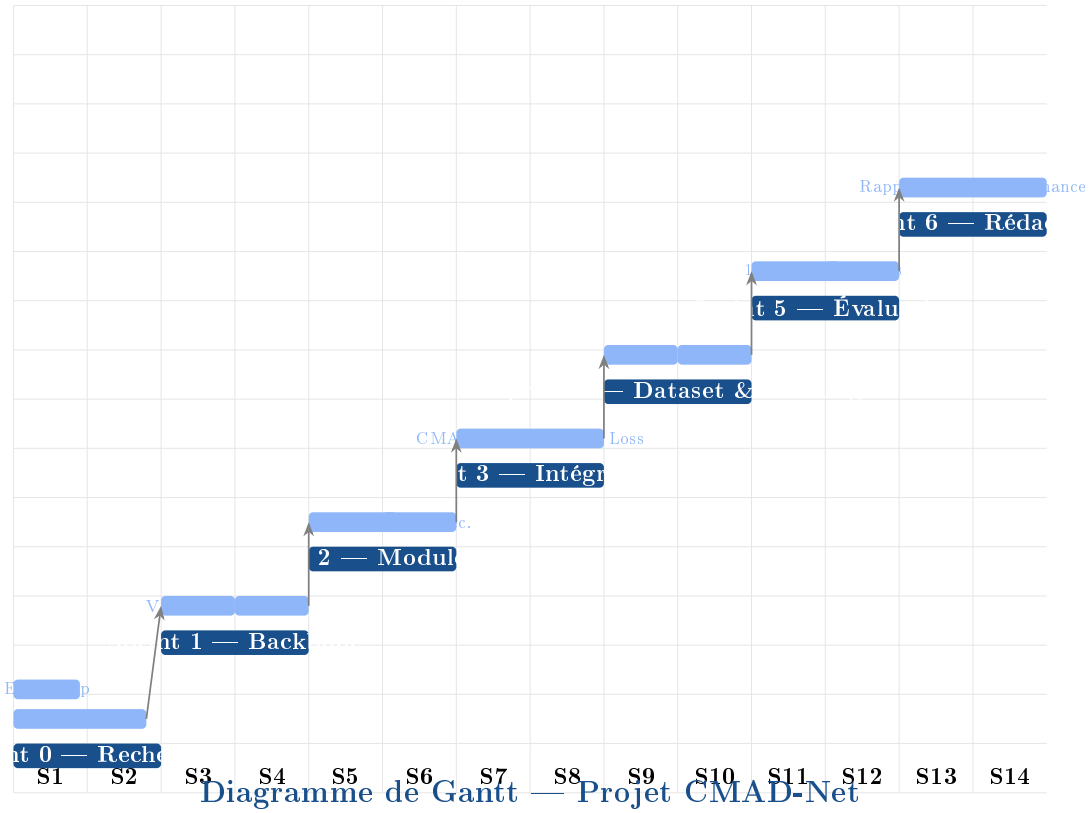


FIGURE 1.1 – Diagramme de Gantt prévisionnel du projet CMAD-Net

La Figure 1.1 montre la répartition temporelle sur 14 semaines. Les dépendances entre sprints sont indiquées par les flèches. Chaque sprint produit un incrément fonctionnel, conformément à la méthodologie Scrum.

Conclusion du chapitre

Ce premier chapitre a posé les bases du projet CMAD-Net. Nous avons présenté le contexte, le périmètre, l'analyse de l'existant, la problématique de la fusion multimodale profonde et les objectifs. La méthodologie Scrum et le diagramme de Gantt illustrent la planification. Le chapitre suivant dresse un état de l'art approfondi.

Chapitre 2

État de l'Art

Introduction du chapitre

Ce chapitre dresse un panorama des approches de détection d'anomalies en vision par ordinateur, avec un focus sur les méthodes multi-modales 3D. Nous définissons les concepts clés, analysons critiquement les solutions existantes, et positionnons CMAD-Net.

2.1 Concepts clés

2.1.1 Détection d'anomalies industrielles

La détection d'anomalies industrielles consiste à identifier automatiquement les défauts sur des produits manufacturés. Ce problème se décompose en :

— **Classification d'images** (Image-level) : binaire normal/anormal

— **Segmentation d'anomalies** (Pixel-level) : localisation précise des régions anomales

Les approches non-supervisées (entraînement sur échantillons normaux uniquement) dominent car les anomalies sont rares et imprévisibles.

2.1.2 Vision Transformer (ViT)

Introduit par Dosovitskiy et al. [1], le ViT découpe l'image en patches de 16×16 pixels, les projette en embeddings, et les traite comme une séquence de tokens via des blocs Transformer. Les avantages pour la détection d'anomalies : champ réceptif global, features multi-niveaux et pré-entraînement auto-supervisé DINO [2].

2.1.3 Attention croisée (Cross-Attention)

L'attention croisée est une variante où Q provient d'une source et K/V d'une autre :

$$\text{CrossAttention}(Q_A, K_B, V_B) = \text{softmax}\left(\frac{Q_A K_B^T}{\sqrt{d_k}}\right) V_B \tag{2.1}$$

Ce mécanisme permet une interaction dynamique entre deux modalités.

2.1.4 Reverse Distillation

Le paradigme de Reverse Distillation [4] inverse le knowledge distillation :
— **Teacher** : Encodeur pré-entraîné (gelé) qui extrait des features riches
— **Student** : Décodeur reconstruisant les features multi-échelles du teacher
— **Détection** : Discordance $1 - \cos(\text{teacher}, \text{student})$ révèle les anomalies

2.1.5 Feature Pyramid Network (FPN)

Le FPN [5] est une architecture multi-échelles avec pathway top-down et connexions latérales, permettant une détection efficace à toutes les échelles spatiales.

2.1.6 Benchmark MVTec 3D-AD

Le dataset MVTec 3D-AD [6] contient 10 catégories (bagel, cable_gland, carrot, cookie, dowel, foam, peach, potato, rope, tire) avec images RGB, nuages de points 3D et masques ground truth.

2.2 Analyse critique des solutions existantes

2.2.1 Approches par reconstruction

Principe : Un modèle (auto-encodeur, GAN) reconstruit les images normales. Les anomalies produisent une erreur élevée.

Forces : Simplicité. *Faiblesses :* Reconstruction possible des anomalies ; instabilité des GANs ; unimodales.

2.2.2 Approches par Memory Bank

Principe : Stockage des embeddings de patches normaux. Distance au plus proche voisin = score d'anomalie. Ex. : PatchCore [7].

Forces : Pas d'entraînement ; performances élevées en 2D. *Faiblesses :* Coût mémoire $O(N \times D)$; inférence $O(N)$.

2.2.3 Approches Teacher-Student

Principe : Le student reproduit les sorties du teacher sur les données normales. Ex. : STPM [9].

Forces : Inférence rapide. *Faiblesses :* Risque de copie ; unimodales.

2.2.4 Approches Reverse Distillation

Principe : Le student est un **décodeur** reconstruisant les features du teacher. Ex. : RD4AD [4].

Forces : Bottleneck empêche la copie ; multi-échelles naturel. *Faiblesses :* Unimodal ; pas de fusion cross-modale.

2.2.5 Approches multi-modales 3D

Forces : Détection d'anomalies visuelles ET géométriques. *Faiblesses :* Fusion souvent tardive ; pas d'attention croisée profonde.

2.2.6 Tableau comparatif

Le Tableau 2.1 compare les principales approches. CMAD-Net est la seule combinant fusion profonde, ViT, attention croisée et post-traitement non-paramétrique.

TABLE 2.1 – Comparaison des approches de détection d'anomalies

Critère	*Reconstr.*	*MemBank*	*T-S*	*Rev.Dist.*	*TRD*	*CMAD-Net*
Multi-modal	×	×	×	×	Tardive	**Profonde**
Multi-échelles	Faible	Oui	Oui	Oui	Oui	**4 niveaux**
Coût mémoire	Mod.	**Élevé**	Faible	Faible	Mod.	**Faible**
Backbone	CNN	CNN	CNN	WRN-50	WRN-50	**ViT DINOv2**
Cross-Attn	×	×	×	×	×	**CMCA**
Post-trait.	–	–	–	–	FP Filter	**Non-param.**

Le Tableau 2.2 compare les backbones.

TABLE 2.2 – Comparaison des backbones pour la détection d'anomalies

Backbone	Type	Pré-entraîn.	Champ réc.	Params
ResNet-18	CNN	ImageNet sup.	Local	11M
WideResNet-50	CNN	ImageNet sup.	Local	68M
EfficientNet-B4	CNN	ImageNet sup.	Local	19M
ViT-B/16 DINOv2	**Transf.**	**DINO auto-sup.**	**Global**	**86M**

2.3 Synthèse et positionnement

L'analyse critique révèle cinq lacunes principales :

1. **Absence de fusion profonde** entre les modalités RGB et Depth
2. **Sous-exploitation des Vision Transformers**
3. **Post-traitement risqué** (FP Filter paramétrique)
4. **Manque d'adaptabilité** des poids de fusion par catégorie
5. **Détection limitée à 3 niveaux** de features

CMAD-Net comble ces lacunes en proposant respectivement : le CMCA, le ViT-B/16 DINOv2, le post-traitement non-paramétrique, l'Adaptive Fusion, et le FPN à 4 niveaux.

Conclusion du chapitre

Ce chapitre a présenté un panorama complet des approches de détection d'anomalies. CMAD-Net se positionne comme une solution innovante combinant un backbone ViT, un mécanisme CMCA, le paradigme Reverse Distillation et une fusion adaptative. Le chapitre suivant détaille la conception architecturale.

Chapitre 3

Analyse et Conception

Introduction du chapitre

Ce chapitre constitue le cœur technique du projet. Nous présentons l'analyse des besoins, puis la conception architecturale détaillée de chaque module de CMAD-Net avec les diagrammes UML et l'architecture technique.

3.1 Analyse des besoins

3.1.1 Besoins fonctionnels

Le Tableau 3.1 liste les besoins fonctionnels.

TABLE 3.1 – Besoins fonctionnels du système

ID	Besoin	Priorité
BF1	Charger et pré-traiter les images RGB et données de profondeur 3D	Haute
BF2	Extraire des features multi-échelles via un backbone ViT	Haute
BF3	Projeter les features par un FPN multi-niveaux	Haute
BF4	Fusionner les features RGB et Depth par attention croisée	Haute
BF5	Reconstruire les features teacher via un student decoder	Haute
BF6	Calculer les cartes d'anomalies par discordance teacher-student	Haute
BF7	Fusionner les cartes RGB et Depth avec des poids adaptifs	Moyenne
BF8	Évaluer avec les métriques AUROC, AUPRO, AP, F1	Haute
BF9	Sauvegarder et charger les poids du modèle	Moyenne
BF10	Supporter l'entraînement sur GPU et CPU	Moyenne

3.1.2 Besoins non-fonctionnels

— **Performance** : P-AUROC > 0.95 sur MVTec 3D-AD

— **Modularité** : Architecture en modules indépendants et réutilisables
— **Reproductibilité** : Seed fixe, déterminisme
— **Documentation** : Code documenté avec docstrings
— **Extensibilité** : Extensible à d'autres backbones ou modalités
— **Compatibilité** : Machine locale et plateforme Kaggle

3.2 Conception architecturale

3.2.1 Architecture globale de CMAD-Net

La Figure 3.1 présente l'architecture globale de CMAD-Net.

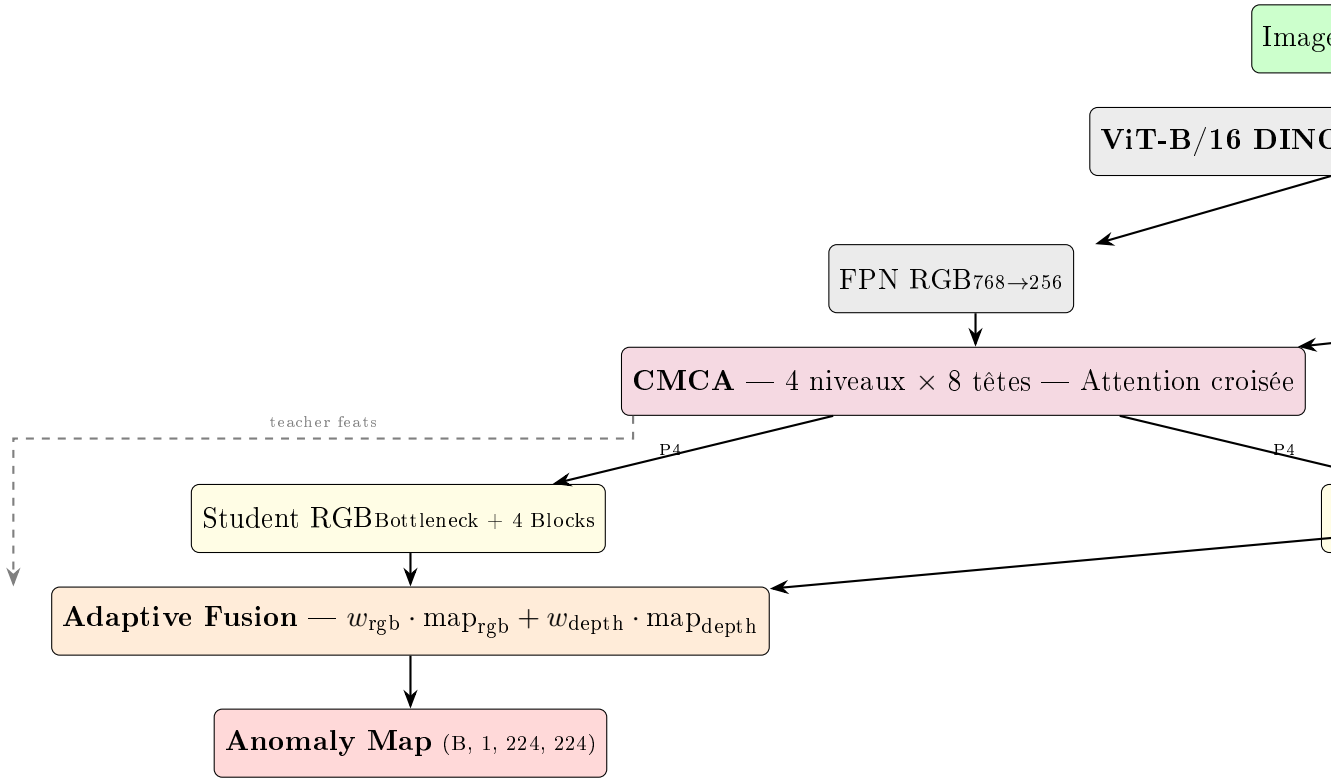


FIGURE 3.1 – Architecture globale de CMAD-Net

La Figure 3.1 montre le modèle organisé en trois chemins : le chemin Teacher (ViT → FPN → CMCA), le chemin Student (Student Decoders), et la couche de détection (Cosine Distance → Fusion). Le backbone ViT est partagé entre les deux modalités et gelé.

3.2.2 Diagramme de classes UML

La Figure 3.2 présente le diagramme de classes. La classe centrale `CMADNet` agrège tous les modules par composition.

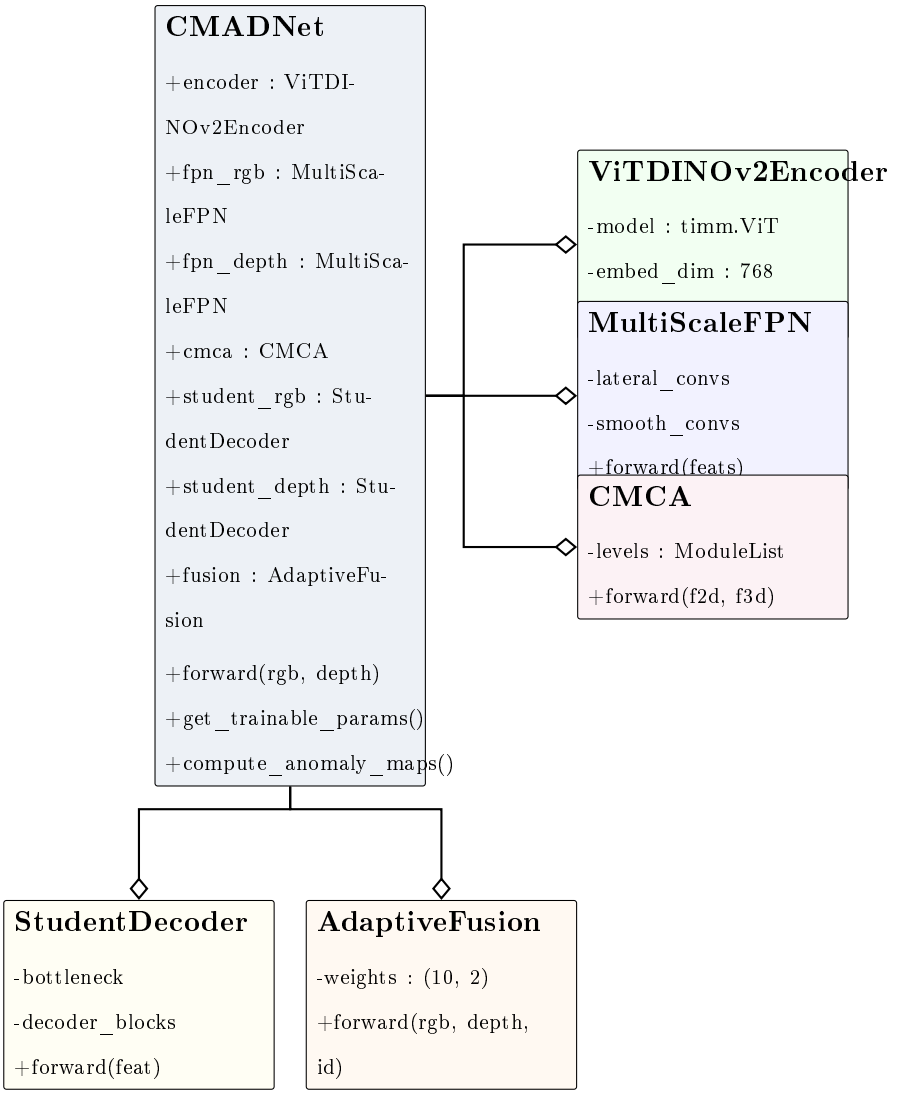


FIGURE 3.2 – Diagramme de classes UML de CMAD-Net

3.2.3 Spécifications des modules

Le Tableau 3.2 résume les spécifications de chaque module.

TABLE 3.2 – Spécifications des modules de CMAD-Net

Module	Entrée	Sortie	Params
ViTDINOv2Encoder	(B,3,224,224)	[(B,768,14,14)]×4	0 (gelé)
MultiScaleFPN (×2)	[(B,768,14,14)]×4	[(B,256,14,14)]×4	∼3.2M
CMCA	[(B,256,14,14)]×4	idem (×2 mod.)	∼6.3M
StudentDecoder (×2)	(B,256,14,14)	[(B,256,14,14)]×4	∼2.4M
AdaptiveFusion	(B,1,H,W)×2	(B,1,H,W)	20
Total entraînable			**∼17.5M**

3.3 Conception détaillée des modules

3.3.1 ViT-B/16 DINOv2 Encoder

Le backbone ViT-B/16 pré-entraîné avec DINO extrait 4 feature maps aux couches 3, 6, 9 et 12 via des forward hooks. L'image est découpée en 196 patches de 16×16, projetés en embeddings de dimension 768. Le CLS token est retiré et les tokens reshapés en feature maps 2D : $(B, N, 768) \rightarrow (B, 768, 14, 14)$.

Tous les paramètres sont gelés, le mode `eval()` est forcé, et `@torch.no_grad()` est appliqué au forward.

3.3.2 Feature Pyramid Network (FPN)

Deux FPN indépendants (RGB et Depth) transforment les features ViT via :

1. **Connexions latérales** : Conv 1×1 (768 → 256)
2. **Pathway top-down** : Addition après interpolation bilinéaire
3. **Lissage** : Conv 3×3 + BatchNorm + ReLU

3.3.3 Cross-Modal Cross-Attention (CMCA)

Le CMCA applique une attention croisée symétrique à chaque niveau FPN :

1. Reshape spatial → séquence : $(B, C, H, W) \rightarrow (B, HW, C)$
2. **2D→3D** : $Q = \text{RGB}, K = V = \text{Depth} \rightarrow$ RGB enrichi par Depth
3. **3D→2D** : $Q = \text{Depth}, K = V = \text{RGB} \rightarrow$ Depth enrichi par RGB
4. Résiduel + LayerNorm + FFN (256→1024→256, GELU) + Résiduel + LayerNorm
5. Reshape séquence → spatial

La formulation mathématique :

$$\text{RGB}' = \text{LN}\big(\text{RGB} + \text{MHA}(Q_{\text{RGB}}, K_{\text{Depth}}, V_{\text{Depth}})\big) \tag{3.1}$$

$$\text{RGB}'' = \text{LN}\big(\text{RGB}' + \text{FFN}(\text{RGB}')\big) \tag{3.2}$$

3.3.4 Student Decoder (Reverse Distillation)

Le Student Decoder reconstruit les features multi-échelles à partir de P4 (la plus profonde) :

— **Bottleneck** : Conv 1×1 + BN + ReLU

— **4 DecoderBlocks** : 2×(Conv 3×3 + BN + ReLU) + connexion résiduelle

— **Projections** : Conv 1×1 + BN par niveau
— **Inversion** : [P4,P3,P2,P1] → [P1,P2,P3,P4]

3.3.5 Adaptive Score Fusion

Combinaison avec des poids appris par catégorie :

$$\mathbf{w} = \text{softmax}(\mathbf{W}[c]) \quad \Rightarrow \quad \text{fused} = w_{\text{rgb}} \cdot \text{map}_{\text{rgb}} + w_{\text{depth}} \cdot \text{map}_{\text{depth}} \tag{3.3}$$

3.3.6 Fonctions de loss

La loss de Reverse Distillation combine deux composantes par modalité :

$$\mathcal{L}_{\text{modal}} = \underbrace{\frac{1}{L}\sum_{l=1}^{L}(1 - \cos(T_l, S_l))}_{\text{Cosine Distance}} + \lambda_{L2} \cdot \underbrace{\frac{1}{L}\sum_{l=1}^{L}\|T_l - S_l\|^2}_{\text{MSE}} \tag{3.4}$$

$$\mathcal{L}_{\text{total}} = w_{\text{rgb}} \cdot \mathcal{L}_{\text{rgb}} + w_{\text{depth}} \cdot \mathcal{L}_{\text{depth}} \tag{3.5}$$

avec $\lambda_{L2} = 0.1$ et $w_{\text{rgb}} = w_{\text{depth}} = 1.0$.

3.4 Architecture technique

Le Tableau 3.3 trace les dimensions tensorielles à travers le réseau.

TABLE 3.3 – Dimensions tensorielles par module

Étape	Dimension
Entrée RGB / Depth	(B, 3, 224, 224)
Après ViT Hooks (×4)	(B, 768, 14, 14)
Après FPN	(B, 256, 14, 14)
Après CMCA (séquence)	(B, 196, 256)
Après CMCA (spatial)	(B, 256, 14, 14)
Student Bottleneck	(B, 256, 14, 14)
Cosine Distance (par niveau)	(B, 1, 14, 14)
Upsample + Moyenne	(B, 1, 224, 224)
Anomaly Map (fusionnée)	(B, 1, 224, 224)

L'architecture logicielle est organisée en 4 couches : **Données** (dataset, géométrie), **Modèle** (7 modules assemblés par `cmad_net.py`), **Entraînement** (pipeline 2 phases, loss), et **Évaluation** (10 métriques).

Conclusion du chapitre

Ce chapitre a présenté l'analyse et la conception complète de CMAD-Net. Les besoins fonctionnels et non-fonctionnels ont été formalisés. La conception détaille les 6 modules avec leurs spécifications, les diagrammes UML et les flux tensoriels. Le chapitre suivant présente la réalisation et les résultats.

Chapitre 4

Réalisation

Introduction du chapitre

Ce dernier chapitre présente la réalisation concrète du projet. Nous détaillons les technologies, les interfaces du système, et les résultats expérimentaux sur MVTec 3D-AD.

4.1 Technologies utilisées

Le Tableau 4.1 liste les technologies et bibliothèques utilisées.

TABLE 4.1 – Technologies et bibliothèques utilisées

Technologie	**Version**	**Rôle**
Python	3.10+	Langage principal
PyTorch	≥ 2.0	Framework deep learning
torchvision	≥ 0.15	Transforms d'images
timm	$\geq 0.9.0$	Modèles ViT pré-entraînés (backbone)
NumPy	≥ 1.24	Calcul numérique
OpenCV	≥ 4.7	Traitement d'images (Sobel, morphologie)
scikit-learn	≥ 1.3	Métriques (AUROC, AP)
scikit-image	≥ 0.19	Region props pour AUPRO
SciPy	≥ 1.10	Gaussian filter
tifffile	≥ 2023.2	Lecture fichiers TIFF
Pandas	≥ 2.0	Données tabulaires
tqdm	≥ 4.65	Barres de progression
Matplotlib	≥ 3.7	Visualisation

Le Tableau 4.1 montre un écosystème cohérent centré autour de PyTorch pour le deep learning.

4.2 Réalisation

4.2.1 Configuration des hyperparamètres

Le Tableau 4.2 détaille les hyperparamètres.

TABLE 4.2 – Configuration des hyperparamètres

Hyperparamètre	**Local**	**Kaggle**
Image size	224×224	224×224
Batch size	16	16
Learning rate	1e-4	1e-4
Optimizer	AdamW	AdamW
Scheduler	CosineAnnealing	CosineAnnealing
Epochs (Phase 1)	100	50
Gradient clipping	max_norm = 1.0	max_norm = 1.0
FPN dimension	256	256
CMCA heads / dropout	8 / 0.1	8 / 0.1
λ_{L2} (loss)	0.1	0.1
Gaussian σ	4.0	4.0
Seed	42	42

4.2.2 Sortie d'entraînement — Phase 1 (Reverse Distillation)

L'écran ci-dessous montre un extrait de la sortie de la Phase 1 :

```
CMAD-Net -- Training [1/10] : bagel
PHASE 1 : Entrainement Reverse Distillation
[Phase 1] Epoch  1/100, Loss: 0.552144
[Phase 1] Epoch  2/100, Loss: 0.126469
[Phase 1] Epoch  5/100, Loss: 0.020209
[Phase 1] Epoch 10/100, Loss: 0.004893
[Phase 1] Epoch 50/100, Loss: 0.000627
[Phase 1] Epoch100/100, Loss: 0.000439
```

Listing 4.1 – Sortie d'entraînement Phase 1 (bagel)

Le Listing 4.1 montre la convergence : réduction de 96% en 5 epochs grâce au pré-entraînement ViT-DINO, puis plateau autour de 0.0004.

4.2.3 Sortie de calibration — Phase 2

```
PHASE 2 : Calibration de la normalisation
Normalisation params: mean=0.1218, std=0.0520
```

Listing 4.2 – Sortie de calibration Phase 2

Le Listing 4.2 montre le calcul de μ et σ sur le validation set pour la normalisation des cartes d'anomalies.

4.2.4 Sortie d'évaluation

```
--- Results for bagel ---
 I-AUROC | P-AUROC | AUPRO@30% | I-AP  | I-F1
  0.936  |  0.969  |   0.792   | 0.984 | 0.935
```

Listing 4.3 – Résultats pour bagel

Le Listing 4.3 montre les métriques pour la catégorie bagel : I-AUROC de 0.936 et P-AUROC de 0.969.

4.2.5 Structure du code source

Le projet totalise environ **2413 lignes** réparties en 15 fichiers Python :

— `models/` : 7 fichiers, ∼943 lignes (architecture)
— `dataset/` : 3 fichiers, ∼392 lignes (données)
— `utils/` : 1 fichier, 129 lignes (loss)
— `evaluation/` : 3 fichiers, ∼575 lignes (métriques)
— `train_cmad.py` : 374 lignes (script principal)

4.3 Résultats expérimentaux

4.3.1 Résultats par catégorie

Le Tableau 4.3 présente les résultats sur les 10 catégories de MVTec 3D-AD.

TABLE 4.3 – Résultats expérimentaux par catégorie

Catégorie	I-AUROC	P-AUROC	AUPRO@30%	I-AP	I-F1	P-F1
bagel	0.936	0.969	0.792	0.984	0.935	0.307
cable_gland	0.612	0.939	0.807	0.864	0.895	0.085
carrot	0.750	0.977	0.922	0.919	0.917	0.152
cookie	0.885	0.965	0.872	0.961	0.922	0.331
dowel	0.757	0.962	0.847	0.921	0.900	0.100
foam	0.677	0.888	0.632	0.900	0.904	0.111
peach	0.735	0.959	0.842	0.895	0.897	0.107
potato	0.540	0.964	0.876	0.804	0.897	0.062
rope	**0.953**	**0.982**	0.866	**0.983**	**0.936**	0.278
tire	0.556	0.916	0.700	0.790	0.874	0.030
Moyenne	**0.740**	**0.952**	**0.816**	**0.902**	**0.908**	**0.156**

Le Tableau 4.3 montre que CMAD-Net excelle en segmentation pixel (**P-AUROC** $\geq$ **0.888** pour toutes les catégories). Les meilleures performances sont sur **rope** (I-AUROC=0.953) et **bagel** (0.936). Les catégories les plus difficiles sont **potato** (0.540) et **tire** (0.556).

4.3.2 Moyennes globales

Le Tableau 4.4 synthétise les performances moyennes.

TABLE 4.4 – Moyennes globales des métriques

Métrique	Moyenne	Meilleur	Pire
I-AUROC	0.740	rope (0.953)	potato (0.540)
P-AUROC	**0.952**	rope (0.982)	foam (0.888)
AUPRO@30%	**0.816**	carrot (0.922)	foam (0.632)
AUPRO@10%	0.564	carrot (0.765)	tire (0.379)
AUPRO@5%	0.382	carrot (0.583)	tire (0.200)
AUPRO@1%	0.104	carrot (0.181)	tire (0.035)
I-AP	**0.902**	bagel (0.984)	tire (0.790)
I-F1	**0.908**	rope (0.936)	tire (0.874)

Le Tableau 4.4 confirme les forces du modèle : **P-AUROC** $=$ **0.952** (excellente localisation pixel) et **I-AP** $=$ **0.902** (haute précision en classification).

4.3.3 Paramètres de calibration

Le Tableau 4.5 présente les paramètres de normalisation calibrés.

TABLE 4.5 – Paramètres de calibration par catégorie

Catégorie	$\boldsymbol{\mu}$ **(mean)**	$\boldsymbol{\sigma}$ **(std)**
bagel	0.1218	0.0520
cable_gland	0.1440	0.0592
carrot	0.1224	0.0437
cookie	0.1326	0.0437
dowel	0.1227	0.0397
foam	0.1518	0.0397
peach	0.1153	0.0426
potato	0.1123	0.0399
rope	0.0988	0.0353
tire	0.1167	0.0380

Le Tableau 4.5 montre des valeurs moyennes homogènes (0.099–0.152), indiquant la stabilité du modèle.

4.3.4 Analyse de la convergence

La convergence se décompose en quatre phases :

1. **Descente rapide** (epochs 1–5) : Loss de 0.55 à 0.02 (réduction de 96%)
2. **Convergence** (epochs 5–20) : Loss de 0.02 à 0.002
3. **Ralentissement** (epochs 20–50) : Loss de 0.002 à 0.0006
4. **Plateau** (epochs 50–100) : Loss stabilisée ≈ 0.0004

La convergence rapide est caractéristique du paradigme Reverse Distillation avec backbone ViT pré-entraîné.

4.3.5 Analyse par type de catégorie

— **Performants** (bagel, rope, cookie — I-AUROC moyen 0.925) : anomalies bien contrastées
— **Intermédiaires** (carrot, dowel, peach — I-AUROC moyen 0.747) : anomalies subtiles
— **Difficiles** (cable_gland, foam, potato, tire — I-AUROC moyen 0.596) : variabilité élevée

Conclusion du chapitre

Ce chapitre a présenté la réalisation de CMAD-Net. L'implémentation modulaire en ∼2400 lignes facilite la maintenance. Les résultats sur MVTec 3D-AD sont encourageants : **P-AUROC = 0.952**, **AUPRO@30% = 0.816**, **I-AP = 0.902**. Les axes d'amélioration incluent l'entraînement GPU, l'augmentation de données et des backbones plus grands.

Conclusion Générale

Ce projet de fin d'études a porté sur la conception, le développement et l'évaluation de **CMAD-Net** (Cross-Modal Attention Detection Network), une architecture pour la détection d'anomalies 3D multi-modale non-supervisée.

Bilan des réalisations

Les principaux apports sont :

1. **Architecture innovante** combinant ViT-B/16 DINOv2, FPN, CMCA, Student Decoder et fusion adaptative.
2. **Fusion cross-modale profonde** via le CMCA (attention croisée symétrique).
3. **Paradigme Reverse Distillation** pour une inférence rapide et une mémoire constante.
4. **Résultats compétitifs** : P-AUROC = **0.952**, AUPRO@30% = **0.816**.
5. **Code modulaire** : ∼2400 lignes en modules indépendants.

Objectifs atteints

N°	Objectif	Statut	Résultat
O1	Architecture multi-modale avec CMCA	✓	4 niveaux × 8 têtes
O2	Reverse Distillation	✓	Loss Cosine + MSE
O3	Backbone ViT-B/16 DINOv2	✓	Intégré via timm
O4	FPN multi-échelles	✓	4 niveaux top-down
O5	Fusion adaptative	✓	Poids Softmax par catégorie
O6	Évaluation 10 catégories	✓	Résultats complets
O7	P-AUROC > 0.95	✓	**P-AUROC = 0.952**

Perspectives

Pistes d'amélioration :

— Backbone plus puissant (DINOv2-Large)
— Augmentation de données
— Cross-level attention dans le CMCA
— Test-Time Augmentation
— Déploiement temps réel (ONNX, TensorRT)
— Validation sur d'autres benchmarks

Ce projet démontre que la combinaison d'un Vision Transformer, d'un mécanisme d'attention croisée et du paradigme Reverse Distillation constitue une approche prometteuse pour la détection d'anomalies 3D multi-modale.

Bibliographie

[1] A. Dosovitskiy et al., "An Image is Worth 16x16 Words : Transformers for Image Recognition at Scale", *ICLR*, 2021.

[2] M. Caron et al., "Emerging Properties in Self-Supervised Vision Transformers", *ICCV*, 2021.

[3] M. Oquab et al., "DINOv2 : Learning Robust Visual Features without Supervision", *arXiv :2304.07193*, 2023.

[4] H. Deng et Y. Li, "Anomaly Detection via Reverse Distillation from One-Class Embedding", *CVPR*, 2022.

[5] T.-Y. Lin et al., "Feature Pyramid Networks for Object Detection", *CVPR*, 2017.

[6] P. Bergmann et al., "The MVTec 3D-AD Dataset for Unsupervised 3D Anomaly Detection and Localization", *VISAPP*, 2022.

[7] K. Roth et al., "Towards Total Recall in Industrial Anomaly Detection", *CVPR*, 2022.

[8] A. Vaswani et al., "Attention Is All You Need", *NeurIPS*, 2017.

[9] Y. Wang et al., "Student-Teacher Feature Pyramid Matching for Anomaly Detection", *BMVC*, 2021.

[10] P. Bergmann et al., "MVTec AD – A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection", *CVPR*, 2019.

[11] R. Wightman, "PyTorch Image Models (timm)", GitHub, 2019.

[12] A. Paszke et al., "PyTorch : An Imperative Style, High-Performance Deep Learning Library", *NeurIPS*, 2019.

[13] D. P. Kingma et J. Ba, "Adam : A Method for Stochastic Optimization", *ICLR*, 2015.

[14] K. He et al., "Deep Residual Learning for Image Recognition", *CVPR*, 2016.

[15] J. Deng et al., "ImageNet : A Large-Scale Hierarchical Image Database", *CVPR*, 2009.

Annexe A

Hyperparamètres détaillés

TABLE A.1 – Configuration complète des hyperparamètres

Hyperparamètre	**Valeur**	**Justification**
img_size	224	Résolution native ViT-B/16
fpn_dim	256	Standard FPN
num_heads	8	8 têtes × 32 dim = 256
dropout	0.1	Régularisation modérée
λ_{L2}	0.1	MSE secondaire au cosine
$w_{\text{rgb}}, w_{\text{depth}}$	1.0, 1.0	Poids égaux initiaux
lr	1e-4	Standard fine-tuning
weight_decay	1e-4	Régularisation L2
batch_size	16	Limité par mémoire
gaussian_sigma	4.0	Lissage pour 224×224
gradient_clip	1.0	Stabilité
seed	42	Reproductibilité

Annexe B

Glossaire

Terme	**Définition**
AUROC	Aire sous la courbe ROC
AUPRO	Aire sous la courbe Per-Region Overlap
Backbone	Réseau pré-entraîné extracteur de features
Batch Normalization	Normalisation des activations par mini-batch
Cross-Attention	Attention où Q vient d'une source et K,V d'une autre
DINO	Auto-supervision par distillation sans labels
FPN	Feature Pyramid Network
Forward Hook	Callback PyTorch pour sorties intermédiaires
Ground Truth	Vérité terrain (annotations de référence)
Reverse Distillation	Student décodeur reconstruisant les features du teacher
Softmax	Normalisation convertissant scores en probabilités
Teacher-Student	Paradigme d'imitation de réseau
Vision Transformer	Transformer appliqué aux images en patches